[Logo oficial CUN]

EduPredict AI

Predicción de deserción universitaria con Machine Learning clásico

[Nombres completos de los integrantes]
Docente: Dr. Hamilton Rivera Flor · Aprendizaje Automático · Especialización en Inteligencia Artificial · CUN

Problema

La deserción universitaria suele detectarse cuando ya es tarde para intervenir.

¿Cómo transformar datos educativos en conocimiento predictivo para anticipar la deserción de un estudiante y facilitar la identificación de posibles situaciones de riesgo académico?

Objetivo

Desarrollar una solución de Machine Learning clásico que permita analizar información académica, entrenar y comparar modelos de clasificación, evaluar su desempeño y presentar predicciones mediante una aplicación interactiva de Streamlit.

Pilar: Educación · Dataset UCI 697 — Predict Students' Dropout and Academic Success

4.424	36	32,1 %	17,9 %	49,9 %
estudiantes	variables predictoras	Deserción	Matriculado	Graduado

Metodología

Datos UCI 697 → Limpieza determinista → Split estratificado 80/20 → Pipelines sin fuga → GridSearchCV 5-fold (macro-F1) → Selección por CV → Evaluación en prueba → App Streamlit

Algoritmos: Regresión Logística · Random Forest · HistGradientBoosting. Desbalance tratado con `class_weight` como hiperparámetro. Modelo adicional de alerta temprana sin variables del 2.º semestre.

Comparación de modelos (prueba, n = 885)

Modelo	Macro-F1 CV	Accuracy	Macro-F1	Bal. acc.
Regresión Logística	0,717	0,724	0,684	0,695
Random Forest	0,724	0,769	0,717	0,716
★ Gradient Boosting (HistGradientBoosting)	**0,730**	**0,729**	**0,688**	**0,697**

Selección por macro-F1 medio en validación cruzada de 5 pliegues; el conjunto de prueba no interviene en la selección.

Clase (Gradient Boosting)	Precisión	Recall	F1
Deserción	0,808	0,697	0,749
Matriculado	0,415	0,597	0,490
Graduado	0,856	0,796	0,825

Matriz de confusión e importancia

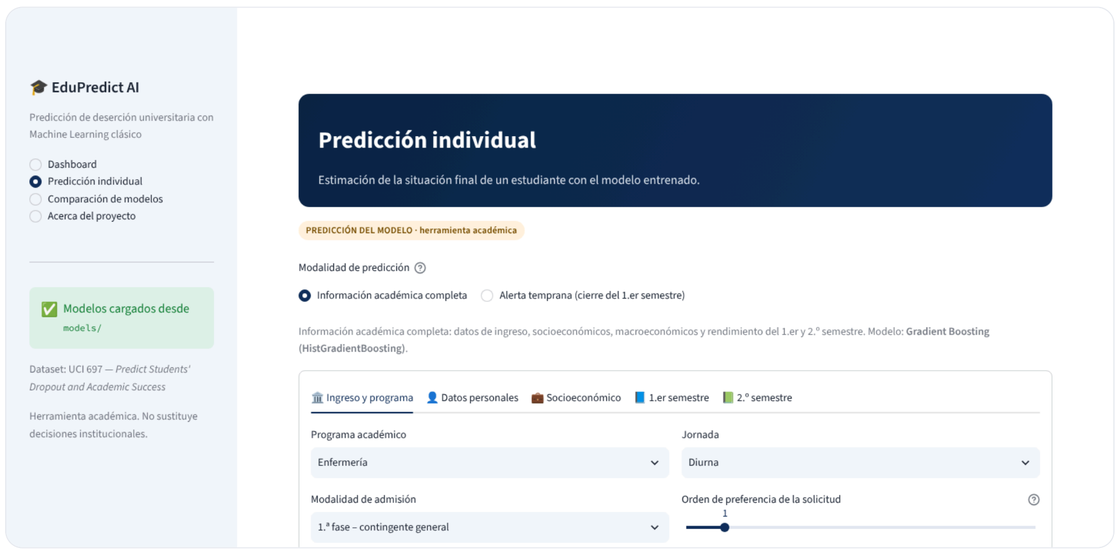
Real \ Pred.	Deserción	Matriculado	Graduado
Deserción	**198**	59	27
Matriculado	32	**95**	32
Graduado	15	75	**352**



Importancia por permutación: caída de macro-F1 al permutar cada variable (asociación, no causalidad).

Alerta temprana (Gradient Boosting): macro-F1 CV 0,699 · macro-F1 prueba 0,669 · accuracy 0,711.

Aplicación Streamlit



Conclusiones

- Los tres algoritmos obtienen desempeños cercanos; Gradient Boosting fue seleccionado por validación cruzada.
- Las unidades aprobadas por semestre y la matrícula al día son las variables de las que más depende el modelo.
- *Matriculado* es la clase más difícil (F1 0,490).
- Con información del 1.er semestre ya es posible una alerta temprana útil, un semestre antes.
- Herramienta académica: identifica asociaciones, no causas, y no reemplaza decisiones institucionales.

Referencias

- Realinho, V., Vieira Martins, M., Machado, J., & Baptista, L. (2021). Predict Students' Dropout and Academic Success [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C5MC89
- Realinho, V., Machado, J., Baptista, L., & Martins, M. V. (2022). Predicting student dropout and academic success. Data, 7(11), 146. https://doi.org/10.3390/data7110146
- Martins, M. V., Tolledo, D., Machado, J., Baptista, L. M. T., & Realinho, V. (2021). Early prediction of student's performance in higher education: A case study. En Trends and Applications in Information Systems and Technologies (pp. 166–175). Springer. https://doi.org/10.1007/978-3-030-72657-7_16
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., … Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

Enlaces

[QR] **App** [URL pública pendiente]

[QR] **Video** [URL pública pendiente]

[QR] **Repositorio** https://github.com/DanielSQN/edupredict-ml-streamlit