EduPredict AI

Predicción de deserción universitaria con Machine Learning clásico

Paula Carolina Calvo Pérez, Juan Sebastián Caviedes Roa, Jonathan Camilo Flórez Bolívar, Daniel Santiago Quintero Niño
Docente: Dr. Hamilton Rivera Flor · Aprendizaje Automático · Especialización en Inteligencia Artificial · CUN

Problema

La deserción universitaria suele detectarse cuando ya es tarde para intervenir.

¿Cómo transformar datos educativos en conocimiento predictivo para anticipar la deserción de un estudiante y facilitar la identificación de posibles situaciones de riesgo académico?

Objetivo

Desarrollar una solución de Machine Learning clásico que permita analizar información académica, entrenar y comparar modelos de clasificación, evaluar su desempeño y presentar predicciones mediante una aplicación interactiva de Streamlit.

Pilar: Educación · Dataset UCI 697 (Realinho et al., 2021)

4.424	36	32,1 %	17,9 %	49,9 %
estudiantes	variables predictoras	Deserción	Matriculado	Graduado

Metodología

Datos UCI 697 → Limpieza determinista → Split estratificado 80/20 → Pipelines sin fuga → GridSearchCV 5-fold (macro-F1) → Selección por CV → Evaluación en prueba → App Streamlit

Algoritmos implementados con scikit-learn (Pedregosa et al., 2011): Regresión Logística · Random Forest (Breiman, 2001) · HistGradientBoosting (Friedman, 2001; Ke et al., 2017). Desbalance tratado con `class_weight` como hiperparámetro. Modelo adicional de alerta temprana sin variables del 2.º semestre.

Comparación de modelos

Tabla 1
Desempeño de los tres algoritmos (prueba, n = 885)

Modelo	Macro-F1 CV	Accuracy	Macro-F1	Bal. acc.
Regresión Logística	0,717	0,724	0,684	0,695
Random Forest	0,724	0,769	0,717	0,716
★ Gradient Boosting (HistGradientBoosting)	**0,730**	**0,729**	**0,688**	**0,697**

Nota. Selección por macro-F1 medio en validación cruzada de 5 pliegues; el conjunto de prueba no interviene en la selección.

Tabla 2
Métricas por clase del modelo seleccionado

Clase (Gradient Boosting)	Precisión	Recall	F1
Deserción	0,808	0,697	0,749
Matriculado	0,415	0,597	0,490
Graduado	0,856	0,796	0,825

Matriz de confusión e importancia

Tabla 3
Matriz de confusión en el conjunto de prueba

Real \ Pred.	Deserción	Matriculado	Graduado
Deserción	**198**	59	27
Matriculado	32	**95**	32
Graduado	15	75	**352**

Figura 1
Variables más influyentes (importancia por permutación)

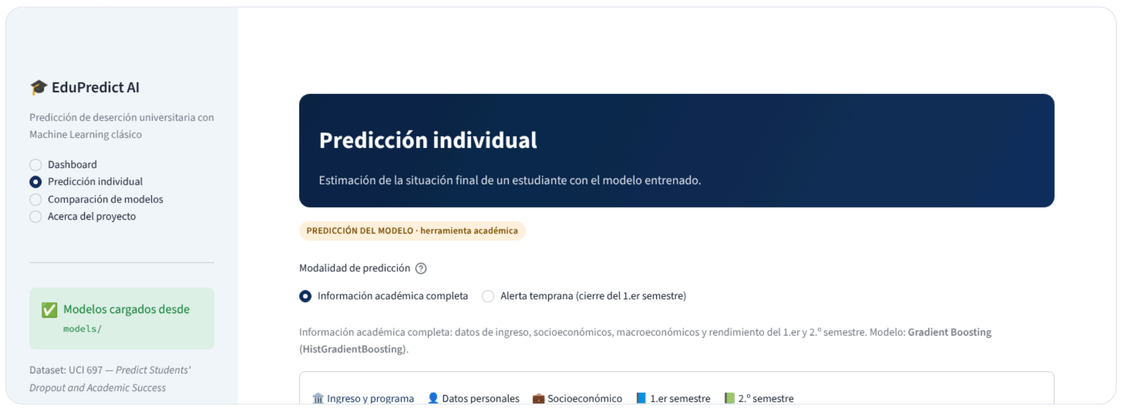


Nota. Caída de macro-F1 al permutar cada variable (asociación, no causalidad).

Alerta temprana (Gradient Boosting): macro-F1 CV 0,699 · macro-F1 prueba 0,669 · accuracy 0,711.

Aplicación Streamlit

Figura 2
Módulo de predicción individual de la aplicación



Nota. Aplicación desarrollada con Streamlit (Streamlit Inc., 2026).

Conclusiones

- Los tres algoritmos obtienen desempeños cercanos; Gradient Boosting fue seleccionado por validación cruzada.
- Las unidades aprobadas por semestre y la matrícula al día son las variables de las que más depende el modelo.
- *Matriculado* es la clase más difícil (F1 0,490).
- Con información del 1.er semestre ya es posible una alerta temprana útil, un semestre antes.
- Herramienta académica: identifica asociaciones, no causas, y no reemplaza decisiones institucionales.

Referencias

Breiman, L. (2001). Random forests. *Machine Learning, 45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics, 29*(5), 1189–1232. https://doi.org/10.1214/aos/1013203451

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems, 30*, 3146–3154.

Martins, M. V., Tolledo, D., Machado, J., Baptista, L. M. T., & Realinho, V. (2021). Early prediction of student's performance in higher education: A case study. En Á. Rocha, H. Adeli, G. Dzemyda, F. Moreira, & A. M. Ramalho Correia (Eds.), *Trends and applications in information systems and technologies* (pp. 166–175). Springer. https://doi.org/10.1007/978-3-030-72657-7_16

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830. https://jmlr.org/papers/v12/pedregosa11a.html

Realinho, V., Machado, J., Baptista, L., & Martins, M. V. (2022). Predicting student dropout and academic success. *Data, 7*(11), Artículo 146. https://doi.org/10.3390/data7110146

Realinho, V., Vieira Martins, M., Machado, J., & Baptista, L. (2021). *Predict students' dropout and academic success* [Conjunto de datos]. UCI Machine Learning Repository. https://doi.org/10.24432/C5MC89

Streamlit Inc. (2026). *Streamlit* (Versión 1.66.1) [Software]. https://streamlit.io

Enlaces

App
https://edupredict-ml-app-cv2fdreafkspczy39oa7nu.streamlit.app/

Video
https://www.youtube.com/watch?v=BEmN8dqMv-o

Repositorio
https://github.com/DanielSQN/edupredict-ml-streamlit